

第四章 网络层：数据平面



学习目标：

- 数据平面上的网络层服务：
 - 网络层服务模型
 - 转发与路由
 - 路由器是如何工作的
 - 通用转发
- 网络层在因特网中的实现

4-1

第四章 网络层：数据平面



4.1 网络层概述

- 数据平面
- 控制平面

4.2 路由器工作原理

4.3 IP协议


- IP数据报格式
- 分片
- IPv4
- 网络地址转换
- IPv6

4.4 通用转发和SDN

4-2

网络层


- 实现源主机到目的主机的IP数据报传输
- 主机和路由器上都有网络层
- 发送方：将报文段封装成IP数据报
- 接收方：将IP数据报数据区交给传输层
- 路由器检查经过的IP数据报的首部，然后转发



4-3

网络层功能


- **转发**：将分组从路由器的输入端口移动到恰当的输出端口
 - 单个路由器
 - **数据平面**
- **路由**：决定分组从源主机到目的主机的传输路径
 - 整个网络
 - **控制平面**
 - 两种实现方法：
 1. **传统的路由协议**：分布式，所有路由器中实现
 2. **软件定义网络software defined network(SDN)**：集中式，远程服务器中实现



4-4

控制平面：传统方法


在各路由器上配置、运行路由协议，生成转发表



4-5

控制平面：SDN方法

远程控制器计算、分发转发表



4-6

网络层服务模型

Q: 网络层提供的服务?

单个数据报:

- 确保交付
- 具有时延上界的确保交付

数据报流:

- 有序交付
- 确保最小带宽
- 时延抖动限制

4-7

不同网络层的服务

网络	服务模型	保证 ?				拥塞反馈
		带宽	无丢包	按序	及时	
Internet	尽力而为	none	no	no	no	no (通过丢包来推断)
ATM	CBR	常速率	yes	yes	yes	无拥塞
ATM	VBR	最小速率保证	yes	yes	yes	无拥塞
ATM	ABR	最小速率保证	no	yes	no	yes
ATM	UBR	none	no	yes	no	no

备注: Constant/Variable/Available/Unspecific Bit Rate

因特网网络层: 尽力而为 $\approx$ 根本没服务

4-8



第四章 网络层：数据平面

4.1 网络层概述

- 数据平面
- 控制平面

4.2 路由器工作原理


4.3 IP协议

- IP数据报格式
- 分片
- IPv4
- 网络地址转换
- IPv6

4.4 通用转发和SDN


4-9

路由器结构



4-10

输入端口



4-11

转发表

转发表	
目的地址范围	输出端口
11001000 00010111 00010000 00000000 到 11001000 00010111 00010111 11111111	0
11001000 00010111 00011000 00000000 到 11001000 00010111 00011000 11111111	1
11001000 00010111 00011001 00000000 到 11001000 00010111 00011111 11111111	2
其他	3

Q: 如果地址范围切分不规整，会怎样? A: 表变很大

解决方法：基于前缀匹配的转发表

4-12

最长前缀匹配

最长前缀匹配

如果有多个匹配项，选择最长匹配的那个

目的地址范围	输出端口
11001000 00010111 00010*** *****	0
11001000 00010111 00011000 *****	1
11001000 00010111 00011*** *****	2
其他	3

举例:

目的地址: 11001000 00010111 00010110 10100001

选哪个端口?

目的地址: 11001000 00010111 00011000 10101010


选哪个端口?

4-13

提高查表速度

Cisco Catalyst路由器: 转发表可能有百万条表项

- 硬件实现
- 使用二分查找，不用顺序查找




2# 1# 0# 3# 2# ...

32层的二叉树，最多32步可找到输出端口

4-14

交换结构

- **作用：**将分组从输入端口转发到正确的输出端口
- 3种交换结构




4-15

内存式交换结构

第一代路由器:


- 传统计算机，CPU控制下进行转发
- 分组存入内存
- 转发速率受内存带宽限制 (每个分组两次使用总线)



4-16

总线式交换结构


- 共享总线
- 转发速率受限于总线带宽
- Cisco 5600: 32Gbps总线, 接入级、企业级路由器



4-17

纵横式交换结构

- $2N$ 条总线, 不受总线带宽限制
- Cisco 12000: 转发速率 60 Gbps




4-18

输入端口排队


- 输入端口速率之和 > 转发速率
 - 时延、丢包
- 线路前部(HOL)阻塞: 输入队列中, 分组被前面的分组阻塞

以纵横式交换结构为例:



4-19

输出端口




- 排队: 转发速率 > 输出端口速率; 时延、丢包
- 分组调度: 队列中选择下一个输出到链路的分组

4-20

先入先出

■ FIFO (first in first out)

- 现实例子?
- 丢弃策略：当分组到达已满队列：
 - 弃尾
 - 按优先级
 - 随机丢弃





4-21

优先级排队

发送优先级高的分组

■ 多个优先级队列

- 分级依据：源/目的IP
地址，端口号等
- 现实例子?




1、3、4为高优先级；2、5为低优先级

4-22

循环排队


- 多个队列
- 循环，每次从一个队列发送一个分组
- 现实例子？



4-23

加权公平排队

- 一般化的循环排队（循环排队+权值）
- 循环，每个队列获得对应权重的服务数量
- 现实例子？



4-24



第四章 网络层：数据平面

4.1 网络层概述

- 数据平面
- 控制平面

4.2 路由器工作原理


4.3 IP协议

- IP数据报格式
- 分片
- IPv4
- 网络地址转换
- IPv6

4.4 通用转发和SDN


4-25

网络层



4-26


IP数据报



4-27

分片与重组

- **最大报文段长度MSS**(Maximum Segment Size) : **TCP数据区**的最大长度,不包含TCP首部
- **最大传输单元MTU**(Maximum Transmit Unit): **帧数据区**的最大长度, 即网络层数据报PDU的最大长度
 - 以太网: 1500B
 - 某些广域网: 576B
 - $MTU = MSS + \text{传输层首部长度} + \text{网络层首部长度}$, 通常, MTU值为MSS值加上TCP header (20 Byte) 和 IPv4 Header (20 Byte) 得到。
- 在某些路由器上分片
- 在目的主机上重组




4-28

分片与重组

分片例子：

- ❖ 4000字节的IP分组
- ❖ 假设IP首部20字节
- ❖ 下一网络的MTU=1500字节

片偏移 = $\frac{1480}{8}$



前面的分片尽可能大


4-29

IPv4地址

- **IPv4地址**：32比特，点分十进制表示，标识设备的网络接口

- 路由器：通常多个网络接口
- 主机：通常1到2个网络接口
(e. g., Ethernet, 802.11)

- 路由器：连接不同网络




点分十进制

223.1.1.1 = $\underbrace{11011111}_{223} \underbrace{00000001}_1 \underbrace{00000001}_1 \underbrace{00000001}_1$

4-30


IPv4地址

有多少个网络?



4-31

接口的互联



4-32

无类别域间路由CIDR

IPv4地址（32位） = 网络号 + 主机号

1. 以前：分类IP地址，网络号长度固定（1、2、3字节）
2. 无类别域间路由CIDR：Classless InterDomain Routing

- 网络号任意长度
- a. b. c. d/x /x：子网掩码：标识网络号

←——— 网络号 ———→ ←——— 主机号 ———→
11001000 00010111 00010000 00000000
200.23.16.0/23

4-33

主机如何获得IP地址？

- 手动设置
 - Windows：网络->属性->本地连接->属性->tcp/ipv4
 - UNIX：/etc/rc.config
- DHCP：Dynamic Host Configuration Protocol：

主机从DHCP服务器自动获取IP地址

- “即插即用”

4-34

DHCP

基于UDP的应用层协议

作用：主机自动获取IP地址


- 地址续约
- 地址重利用
- 但移动用户无法保持连接（第7章）

DHCP步骤：

- 主机广播发送 “DHCP discover” 报文[可选]
- DHCP 服务器广播响应 “DHCP offer” 报文[可选]
- 主机选择服务器，广播发送 “DHCP request” 报文
- DHCP服务器广播返回 “DHCP ack” 报文


4-35

DHCP例子



4-36

DHCP例子



4-37

DHCP


DHCP自动获取:

- 主机IP地址
- 子网掩码
- 默认网关
- DNS服务器

```
连接特定的 DNS 后缀 . . . . . : 
描述 . . . . . : Intel(R) Wi-Fi 6 AX201 160MHz
物理地址 . . . . . : 4C-44-5B-21-66-32
DHCP 已启用 . . . . . : 是
自动配置已启用 . . . . . : 是
IPv6 地址 . . . . . : 2408:823d:214:eal:a9cb:dc5:4843:ac9f(首选)
IPv6 地址 . . . . . : 2408:823d:214:eal:f89a:78e7:12a3:5(首选)
获得租约的时间 . . . . . : 2024年5月20日 11:15:49
租约过期的时间 . . . . . : 2024年5月21日 0:15:50
临时 IPv6 地址 . . . . . : 2408:823d:214:eal:513a:97fb:bc7:1d8f(首选)
IPv6 地址 . . . . . : 2408:823d:214:eal:f89a:78e7:12a3:4(复制)
获得租约的时间 . . . . . : 2024年5月16日 15:28:22
租约过期的时间 . . . . . : 2024年5月20日 22:44:32
本地链接 IPv6 地址 . . . . . : fe80::7e16:d671:ec47:d77b%13(首选)
IPv4 地址 . . . . . : 192.168.168.221(首选)
子网掩码 . . . . . : 255.255.255.0
获得租约的时间 . . . . . : 2024年5月16日 8:41:40
租约过期的时间 . . . . . : 2024年5月21日 18:03:19
默认网关 . . . . . : fe80::1%13
                  192.168.168.100
DHCP 服务器 . . . . . : 192.168.168.100
DHCPv6 IAID . . . . . : 139215963
DHCPv6 客户端 DUID . . . . . : 00-01-00-01-2A-E9-4C-DE-00-4C-E0-86-07-8F
DNS 服务器 . . . . . : fe80::1%13
                  192.168.168.100
TCP/IP 上的 NetBIOS . . . . . : 已启用
```

4-38


DHCP: 例子



- 客户机用DHCP来获取：
IP地址，子网掩码，默认网关，DNS地址
- 客户机：自上而下，DHCP request报文封装到UDP、IP和Ethernet帧
- 帧在网络内广播，被运行DHCP的路由器收到
- 自下而上解封装

4-39

DHCP: 例子



- 服务器生成DHCP ACK，包含IP地址、子网掩码等；
封装->广播->解封装
- ❖ 客户机获得参数之后，
正常上网

4-40

Wireshark 抓包分析

DHCP request报文

Message type: **Boot Request (1)**
Hardware type: Ethernet
Hardware address length: 6
Hops: 0
Transaction ID: 0x6b3a11b7
Seconds elapsed: 0
Bootp flags: 0x0000 (Unicast)
Client IP address: 0.0.0.0 (0.0.0.0)
Your (client) IP address: 0.0.0.0 (0.0.0.0)
Next server IP address: 0.0.0.0 (0.0.0.0)
Relay agent IP address: 0.0.0.0 (0.0.0.0)
Client MAC address: Wistron_23:68:8a (00:16:d3:23:68:8a)
Server host name not given
Boot file name not given
Magic cookie: (OK)
Option: (t=53,l=1) **DHCP Message Type = DHCP Request**
Option: (61) Client identifier
Length: 7; Value: 010016D323688A;
Hardware type: Ethernet
Client MAC address: Wistron_23:68:8a (00:16:d3:23:68:8a)
Option: (t=50,l=4) Requested IP Address = 192.168.1.101
Option: (t=12,l=5) Host Name = "nomad"
Option: (55) Parameter Request List
Length: 11; Value: 010F03062C2E2F1F21F92B
1 = Subnet Mask; 15 = Domain Name
3 = Router; 6 = Domain Name Server
44 = NetBIOS over TCP/IP Name Server
.....

DHCP reply报文

Message type: **Boot Reply (2)**
Hardware type: Ethernet
Hardware address length: 6
Hops: 0
Transaction ID: 0x6b3a11b7
Seconds elapsed: 0
Bootp flags: 0x0000 (Unicast)
Client IP address: 192.168.1.101 (192.168.1.101)
Your (client) IP address: 0.0.0.0 (0.0.0.0)
Next server IP address: 192.168.1.1 (192.168.1.1)
Relay agent IP address: 0.0.0.0 (0.0.0.0)
Client MAC address: Wistron_23:68:8a (00:16:d3:23:68:8a)
Server host name not given
Boot file name not given
Magic cookie: (OK)
Option: (t=53,l=1) DHCP Message Type = DHCP ACK
Option: (t=54,l=4) Server Identifier = 192.168.1.1
Option: (t=1,l=4) Subnet Mask = 255.255.255.0
Option: (t=3,l=4) Router = 192.168.1.1
Option: (6) Domain Name Server
Length: 12; Value: 445747E2445749F244574092;
IP Address: 68.87.71.226;
IP Address: 68.87.73.242;
IP Address: 68.87.64.146
Option: (t=15,l=20) Domain Name = "hsd1.ma.comcast.net."

4-41

ISP如何获得IP地址块?

A: ICANN: Internet **C**orporation for **A**ssigned

Names and **N**umbers

因特网名字和编号分配机构

- 分配IP地址
- 分配域名
- 管理DNS根服务器

4-42


地址块的二次分配

假设分配给8个子网络：

ISP地址块	<u>11001000</u>	<u>00010111</u>	<u>00010000</u>	00000000	200.23.16.0/20
网络0	<u>11001000</u>	<u>00010111</u>	<u>00010000</u>	00000000	200.23.16.0/23
网络1	<u>11001000</u>	<u>00010111</u>	<u>00010010</u>	00000000	200.23.18.0/23
网络2	<u>11001000</u>	<u>00010111</u>	<u>00010100</u>	00000000	200.23.20.0/23
...				...	
...					
网络7	<u>11001000</u>	<u>00010111</u>	<u>00011110</u>	00000000	200.23.30.0/23


4-43

层次式寻址




4-44

层次式寻址



4-45

网络地址转换NAT



私有IP地址（无需申请，且可重用）：

10.0.0.0/8: 10.0.0.0-10.255.255.255

172.16.0.0/12: 172.16.0.0-172.31.255.255

192.168.0.0/16: 192.168.0.0-192.168.255.255

4-46

网络地址转换NAT

作用: :

- 只使用一个公有IP地址，节约地址
- 内网地址变动，不用通知外网
- 更换ISP，无需更改内网
- 内网结构不可见，更安全

4-47


网络地址转换NAT

实现: NAT路由器上:

- 出去的分组: 替换 (源IP地址, 端口 #) 为 (NAT IP地址, 新的端口#), 并记录
... 远方主机将 (NAT IP地址, 新的端口#) 作为目的地址返回应答
- 进来的分组: 逆向替换

4-48

网络地址转换NAT



网络地址转换NAT

- NAT的争议:
 - 路由器只应处理网络层及其以下层（端口）
 - 违反主机间直接对话原则
 - IP地址短缺问题有IPv6

IPv6

- **初始动机**：32位的IPv4地址不够用
- **其它作用**：
 - 首部格式简化，加速路由器的处理转发
 - 首部格式方便QoS（Quality of Service，服务质量）路由

IPv6分组：

- 40字节固定首部+0到多个扩展首部

格式：128bit，每16bit划分为一段，总共8段，每段用冒号隔开，称为“冒号十六进制表示法”，如下：

fe80:0000:0001:0000:0440:44ff:1233:5678

如地址中有很多0，就可以把连续的一段0压缩为 ::，但一个地址中只能有一个::， 如下：

fe80:0000:0000:0000:0000:0000:0001:0000 → fe80::0001:0000


4-51

IPv6分组格式

服务类型：低时延、高吞吐量、高可靠性

流标签：标记同一个流中的分组

下一首部：指出扩展首部类型



← 32 bits →

4-52


与IPv4的其它不同

- **校验和**: 去掉, 提高转发效率, 不在每跳进行校验, 由链路层和传输层进行校验
- **分片**: 去掉, 提高转发效率, 太大丢弃并向源发送错误 (ICMPv6), 由源改小
- **选项**: 放在扩展首部
- **ICMPv6**:
 - 增加错误类型, e. g. “Packet Too Big”
 - 增加组播组管理

4-53


IPv4向IPv6过渡

- 路由器无法同时升级
 - 同时存在IPv4和IPv6的路由器, 如何通信?
- **隧道**: 两台IPv6路由器之间的中间IPv4路由器的集合
- **建隧道**: 将IPv6分组封装到IPv4分组, 在IPv4路由器间传输




4-54

建隧道



4-55

建隧道



4-56

IPv6的部署

- Google: 8%的用户采用IPv6
- 1/3 的美国政府机构域名支持IPv6
- 部署要较长时间
 - 应用层能快速部署: WWW, Facebook, streaming media, Skype, ...
 - Why?

4-57

第四章 网络层：数据平面



- 4.1 网络层概述
 - 数据平面
 - 控制平面
- 4.2 路由器工作原理
- 4.3 IP协议
 - IP数据报格式
 - 分片
 - IPv4
 - 网络地址转换
 - IPv6
- 4.4 通用转发和SDN
 - 匹配
 - 动作
 - OpenFlow举例


4-58

通用转发与SDN

基于目的地址的转发：转发表，但无法NAT、防火墙、负载均衡等

通用转发：

各路由器含有一个流表（远程控制器计算和分配）




4-59

OpenFlow数据平面

OpenFlow: 标准，含远程控制器、SDN、通用转发

■ **通用转发**（流表的匹配+动作）：

- **匹配**：根据收到分组的首部查找流表
- **动作**：匹配成功：丢弃、转发、修改、发送到控制器
- **优先级**：区分重叠表项
- **计数器**：匹配成功的数量（分组数、字节数）




4-60

OpenFlow数据平面

OpenFlow: 标准, 含远程控制器、SDN、通用转发

通用转发（流表的匹配+动作）：


- **匹配**：根据收到分组的首部查找流表
- **动作**：匹配成功：丢弃、转发、修改、发送到控制器
- **优先级**：区分重叠表项
- **计数器**：匹配成功的数量（分组数、字节数）



1. src=1.2.*.*, dest=3.4.5.* → 丢弃
2. src = *.*.*, dest=3.4.*.* → 转发(2)
3. src=10.1.2.3, dest=*.*.* → 发送到控制器

4-61

OpenFlow: 流表的表项



4-62

例子

基于目的地址的转发:

输入端口	源MAC	目的MAC	以太网类型	VLAN ID	源IP	目的IP	IP协议TOS	源端口	目的端口	动作
------	------	-------	-------	---------	-----	------	---------	-----	------	----

* * * * * 51.6.0.8 * * * port6

去往51.6.0.8的分组转发到端口6

防火墙:

输入端口	源MAC	目的MAC	以太网类型	VLAN ID	源IP	目的IP	IP协议TOS	源端口	目的端口	动作
------	------	-------	-------	---------	-----	------	---------	-----	------	----

* * * * * * * * 22 drop

所有去往22端口的分组, 丢弃

输入端口	源MAC	目的MAC	以太网类型	VLAN ID	源IP	目的IP	IP协议TOS	源端口	目的端口	动作
------	------	-------	-------	---------	-----	------	---------	-----	------	----

* * * * * 128.119.1.1 * * * * drop

所有来自128.119.1.1的分组, 丢弃

4-63

例子

基于目的地址的第2层转发（交换机）:

输入端口	源MAC	目的MAC	以太网类型	VLAN ID	源IP	目的IP	IP协议TOS	源端口	目的端口	动作
------	------	-------	-------	---------	-----	------	---------	-----	------	----

* 22:A7:23:11:E1:02 * * * * * * * * port3

来自于链路层22:A7:23:11:E1:02的分组, 转发到3号端口

4-64

OpenFlow特点

通用转发(匹配+动作): 统一了多种设备:

路由器

- 匹配: 最长IP地址前缀
- 动作: 转发

防火墙

- 匹配: IP地址和端口号
- 动作: 允许或拒绝

交换机

- 匹配: 目的MAC地址
- 动作: 转发或广播


NAT

- 匹配: IP地址和端口号
- 动作: 修改IP地址和端口号

4-65

OpenFlow例子

例子: 将分组从h5和h6通过s1和s2发送给h3和h4



4-66

第四章 网络层：数据平面

Q: 转发表、流表如何计算得到?

A: 网络层的控制平面(下一章)